

UniSafe Skills: 统一 Schema 下的跨模态内容安全 Guard 评测

方向 A (Dataset Skill) + 方向 B (Guard Skill) 配套实验平台

[学生甲 (方向 A)] [学生乙 (方向 B)]

2026-06-17

摘要

本报告构建了一个以统一 JSONL schema 与统一 Guard 结果接口为核心的内容安全评测平台：方向 A 将三个安全数据集（文本 WildGuardMix + XSTest 过度拒答探针、图像 UnsafeBench）规整为同一格式，方向 B 用同一套 Guard 接口跨文本/图像模态封装多种 guard 并评测。文本侧 Llama Guard 3 在 1,959 条真实测试集上取得 AUROC 0.888、过度拒答率 6.4%，表现稳健；图像侧 ShieldGemma 2 (int8) 受三策略覆盖与 19.4% 的量化 NaN 限制，AUROC 仅 0.613 (CPU bf16 真值 0.719)。我们以双口径指标 (answered_only / failure_as_wrong) 防止“剔除失败样本导致虚高”，以阈值校准 (而非 ensemble) 作为效果杠杆，并以逐记录 NaN 回退 (E3) 把图像侧覆盖率从 80.6% 补回至投影 ~100%。全部结果数字均由保存的预测复算、与权威 metrics.md 逐位一致，并对三类结构上限 (三策略天花板、判官对抗坍塌、int8 量化漂移) 如实定位、不声称解决。

关键词：内容安全 Guard；统一 schema；Llama Guard；ShieldGemma 2；双口径评测；阈值校准；可复现性。

Keywords: content-safety guard; unified schema; Llama Guard; ShieldGemma 2; dual-basis evaluation; threshold calibration; reproducibility.

1 引言 (项目概述)

本作业要求两人一组、以流水线方式协作：方向 A 产出“内容安全数据集 → 统一 JSONL”的 Dataset Skill，方向 B 产出“封装 Guard 模型/规则/API → 统一安全判断”的 Guard Skill，且方向 B 必须在方向 A 构造的数据集上完成评测。我们锁定的统一叙事是：同一套 unified schema 与同一个 Guard 结果接口，跨文本与图像模态泛化——这直接回应作业“统一实验平台”的目标。

方案采用“文本核心 + 多模态亮点”：文本侧做扎实、先过格式校验再出指标，图像侧严格限定小样本以保护可复现性。分工上，甲负责两个 dataset skill (dataset-wildguardmix、dataset-unsafebench)，乙负责两个 guard skill (guard-llama-guard、guard-shieldgemma2)，贡献约各半。本报告聚焦方向 B 的 guard 方法与联合实验 (第 3–6 节)；第 2 节 (方向 A 数据集) 由甲撰写。全文围绕作业评分三轴展开：结构与功能完整性、可复现性、结果与报告。

2 数据集构建说明与分析（方向 A）

【本节留给方向 A 同学（甲）撰写：数据集选型与统一 *schema*、规模与基准率（含 *safe* / 安全探针样本对 *FPR* 与过度拒答率的支撑）、通过 *dataset-format-checker* (*exit 0*) 的质量门，以及 *caption* 真数据覆盖等 *caveat*。乙不代写；写作要点与必读证据见 报告大纲.md 第 1 节与“证据地图”。】

3 Guard 方法说明与分析（方向 B）

3.1 Guard 矩阵

文本侧三种 guard 互为对照：(1) **Llama Guard 3-1B**，本地推理，以 *unsafe* 词元的归一化概率为连续置信分；(2) **规则基线**，纯关键词、零依赖，仅给 0/1 判定，因此无连续分、不计 *AUROC*（如实标注，而非缺数据）；(3) **LLM-as-judge**，调用商用 API，自报置信度经“方向映射”后才参与 *AUROC*（未映射前实测仅 0.375，跨 guard 的 *AUROC* 不可直接混比）。图像侧为 (4) **ShieldGemma 2-4B**，本地 int8 量化，仅 *dangerous* / *sexual* / *violence* 三策略；(5) **caption-rule**，零依赖的标题/OCR 关键词基线。

3.2 统一 Guard 结果接口

五个 guard 共享同一输出 *schema*、同一退出码契约（0 成功 / 2 部分可用 / 3 致命）、以及“结果分层状态机”（*fallback_only* → *partial* → *full*）。图像 guard 与文本 guard 的输出记录 **零 schema 变更**，使同一套指标机与同一份评测脚本可直接跨模态复用——这是“统一平台”在工程层面的落点。

3.3 Skill 工程质量

围绕评分中权重最高的“结构与功能”与“可复现性”，我们落实了若干工程纪律：(a) **标准 Skill 结构**（*SKILL.md* + *scripts/references/schemas/templates/examples/tests*），零安装即可 `python scripts/main.py` 运行；(b) **受控复制纪律**：*validate.py*/*metrics.py*/*calibrate.py* 在文本与图像两侧镜像，并以“答案钥双算”锁定一致；(c) **双口径指标**（见 §4.3）防止量化失败被静默剔除而虚高；(d) **优雅降级**：门控模型缺访问时以退出码 2 + 可复制修复提示退出而非崩溃，逐条 *try/except* 计数，软超时丢弃迟到结果；(e) **可复现性硬化**：*run_metadata* 记录 *model_revision* 与库版本、固定随机种子、提供 `--limit smoke` 路径。

4 实验流程、结果报告与分析

4.1 实验流程

实验按里程碑推进：M1 打通文本端到端 → M2 多 Guard 横向对比 + 过度拒答 + 对抗/类别分桶 → M3 图像多模态亮点 → M3.5 性能优化 → M3.6 判别效果优化（阈值校准）→ M3.7 图

像覆盖率回退 (E3)。全程坚持”先文本扎实、多模态限小样本”，以免拖垮可复现性。本节所有数字取自 `report_artifacts/result_summary.csv` (由保存的逐条预测复算，与权威 `metrics.md` 逐位一致)。

4.2 文本侧结果

表 1 给出文本侧三 guard 的 `answered_only` 战绩，图 1 直观对比 Accuracy / F1 / Coverage。Llama Guard 综合最强：AUROC 0.888、Accuracy 0.899、Recall 0.660 (95% CI [0.601, 0.715])、FPR 0.063，且失败率仅 2.4%。过度拒答方面，在 250 条 XSTest 安全探针上误报率 6.4%。对抗鲁棒性可量化：Llama Guard 的 AUROC 从非对抗 0.919 降到对抗 0.831；而 LLM-judge 虽然召回最高 (0.750, CI [0.598, 0.858])，其 FPR 也最高 (0.152)，且对抗下坍塌最严重 (AUROC 0.976 $\rightarrow$ 0.633) ——印证”推理判官范式”相对专用 guard 的结构弱点。我们另实测否定了 ensemble: rule+llama 的 OR/AND 组合无一在 F1 上胜过 Llama Guard 单独，阈值校准才是真正效果杠杆 (见 §4.5)。

表 1: 文本侧 guard 战绩 (`answered_only` 口径；正类 =unsafe；规则基线无连续分故 AUROC=N/A)。judge 子集为分层 120 条 (40 unsafe/40 safe/40 XSTest)，基准率与全量 1,959 不同，故 Accuracy/FPR 不与全量直接可比，AUROC 更可比。

guard	<i>n</i>	Acc	Recall	FPR	Macro-F1	AUROC
rule	1959	0.798	0.271	0.112	0.582	N/A
Llama Guard 3-1B	1959	0.899	0.660	0.063	0.792	0.888
LLM-judge	120	0.815	0.750	0.152	0.795	0.895




图 1: 各 guard 的 Accuracy / F1(unsafe) / Coverage (`answered_only`)。Llama Guard 文本侧 Acc/F1 最高；图像 guard 的 F1 极低且覆盖率有缺口。柱标 *n* = eligible。

4.3 图像侧结果

图像侧的核心是量化与覆盖率的双重制约（表 2，图 2）。ShieldGemma 2 在 int8 下 AUROC 仅 0.613，而同模型 CPU bf16 无量化参考为 0.719——**0.613 是量化退化下界，不是模型真实水平**，报告须双值并报。失败侧，int8 在自然图像上有 **19.4%（395/2037）** 的确定性 NaN（同图每次坏成一样），caption-rule 则因真图缺乏描述性标题而近乎失明（Recall 0.020、覆盖率仅 0.701，609 条因缺图/缺 caption 计为 error）。即使用 CPU 真值，ShieldGemma 2 也受三策略天花板限制：UnsafeBench 的 11 个类别里 8 类无对应策略，AUROC 约 0.72 即封顶——属结构上限，非校准/工程可解。

表 2：图像侧 guard 战绩（answered_only）。CPU bf16 为无量化真值参考（非生产精度）；+E3 为对 int8-NaN 子集回退后的恢复子集（见 §4.6）。

guard（精度）	<i>n</i>	Acc	Recall	FPR	Macro-F1	AUROC	Coverage
caption-rule	2037	0.605	0.020	0.014	0.395	N/A	0.701
ShieldGemma2 int8（生产）	2037	0.622	0.125	0.051	0.480	0.613	0.806
ShieldGemma2 CPU bf16（参考）	150	0.733	0.350	0.011	0.664	0.719	1.000
ShieldGemma2 +E3（NaN 子集）	100	0.790	0.393	0.056	0.689	0.675	1.000




图 2：record-level 失败的来源与规模。图像侧主导：caption 缺失 609（29.9%）+ int8 NaN 395（19.4%）；文本 guard 仅约 2.5%。

4.4 双口径指标（防虚高护栏）

对会失败的 guard，“剔除失败”会让指标偏乐观，“失败计错”会偏悲观，真值落在两者之间——我们因此强制并报双口径（图 3）。落差与失败率成正比：caption-rule 的 Accuracy 从 0.605 降到 0.424（ $\Delta - 0.18$ ）、ShieldGemma 2 int8 从 0.622 降到 0.502（ $\Delta - 0.12$ ），而文本侧 Llama

Guard 仅 $\Delta - 0.02$ 。这张图本身就是”双口径 = 工程护栏”的活例。




图 3: answered_only 与 failure_as_wrong 两口径的 Accuracy 对比。失败率越高，两口径落差越大；剔除失败会虚高，故必须并报。

4.5 效果优化: before → after (M3.6 阈值校准)

我们以 ROC 阈值扫描得到生产阈值并落为默认。Llama Guard 由原生 argmax 调到阈值 0.55: 这不是 Macro-F1 杠杆而是 precision-favoring 操作点——对真实旧行为, Macro-F1 几乎持平, 真实赢点是 FPR 0.063 → 0.056、过度拒答 6.4% → 6.0%，代价是召回约降 3%（如实口径, 详见 M3.6_summary.md §2.0）。ShieldGemma 2 由 0.5 调到 0.30（取 FPR ≤ 0.1 档而非 max_macro_f1=0.05/FPR 38% 的不可接受点）: Macro-F1 0.480 → 0.523、Recall 0.125 → 0.198, FPR 仍守 < 0.1。

4.6 图像覆盖率回退 (M3.7 / E3)

针对 int8 的 19.4% NaN，我们实现逐记录 NaN 回退：当 int8 返回 NaN 时，对该单图回退到非量化精度（CPU bf16）重算，默认关闭（--nan-fallback none 复现旧行为）。在 100 张 NaN 子集上恢复 100/100，子集覆盖率 0% → 100%、全量覆盖率投影 80.6% → ~100%（图 4）。恢复分是 truth-grade（子集 AUROC 0.675，贴近 CPU 真值 0.719、远高于 int8 下界 0.613）。但必须诚实：E3 是覆盖率/鲁棒性赢点，不是 int8 质量修复——全量在 E3 后为混精度（多数仍是漂移的 int8），且 0.30 阈值在 int8 上校准、套在 bf16 上非最优。




图 4: 文本/图像/图像 +E3 的覆盖率对照。图像侧被 int8 NaN 拉到 0.806，E3 逐记录回退补回 ~1.00；文本侧本就高覆盖 0.976。蓝/橙为正式实验，绿为 E3 回退（非机制验证）。

4.7 性能与可复现性

M3.5 把 LLM-judge 的并发从串行提到 4 路，实测 340s → 88s (**3.86×**)，且逐 id 结果一致；int8 重跑 flip_rate=0（确定性）。交付前复现核对：两侧单测 guard-llama-guard 105 / guard-shieldgemma2 110 全绿，干净 clone 可离线复现 rule guard 的”预测 → 评分”全链；真数据级指标的复现需 GPU + HuggingFace 缓存 + 真实数据集（数据/权重按设计不入库，如实定位）。

4.8 结构上限（未解决，仅定位）

三类上限属结构性、非本轮校准/工程能解：(1) ShieldGemma 2 三策略天花板（AUROC 即便 CPU 真值也 ~0.72 封顶，需换多策略模型）；(2) 判官对抗坍塌（AUROC 0.976 → 0.633）；(3) int8 量化漂移（连非-NaN 分也仅约一半可信，E3 只补覆盖、不动质量）。报告对此如实呈现，不声称解决。

5 结论与局限

本平台证明了”统一 schema + 统一 Guard 接口跨模态泛化”的可行性：文本侧 Llama Guard 强（AUROC 0.888），工程质量与可复现性扎实，效果以阈值校准而非 ensemble 提升，图像覆盖率以 E3 逐记录回退补回。局限是结构性的——三策略天花板、判官对抗坍塌、int8 量化漂移，E3 只补覆盖、未解此三者。后续方向：换非量化精度以解 int8 漂移、换多策略图像模型以解三策略天花板。

6 小组成员贡献度

分工约各半 (~50/50), 按 CRediT 角色: 甲(方向 A) 负责数据获取、统一格式转换、taxonomy 映射与通过 `dataset-format-checker` (`dataset-wildguardmix`、`dataset-unsafebench`)。乙(方向 B) 负责 `guard` 方法封装、统一指标机与双口径实现、阈值校准、性能优化与可复现性硬化、E3 覆盖率回退及结果分析与图表 (`guard-llama-guard`、`guard-shieldgemma2`)。共同完成 M0 接口契约、22 类 canonical taxonomy 映射与本报告。

声明

AI 使用: 本项目在编码、结果复算与报告起草中使用了 AI 辅助工具 (Claude Code); 所有结果数字均来自本组自有实验、由保存的预测复算并经人工核对, 无人工填造。**数据与代码可得性:** 代码与聚合结果见仓库 Lang-Qiu/unisafe-skills; 真实数据集与模型权重依许可与体积不入库 (可由 dataset skill 在线重建)。复算与绘图脚本见 `report_artifacts/`。

参考资源

- WildGuardMix 数据集 (`allenai/wildguardmix,odc-by`); XSTest 过度拒答探针 (`walledai/XSTest`)。
- UnsafeBench 图像数据集 (`yiting/UnsafeBench`)。
- Llama Guard 3-1B (`meta-llama/Llama-Guard-3-1B`); ShieldGemma 2-4B (`google/shieldgemma-2-4b-it`)。
- 格式校验器 `dataset-format-checker` (嵌套 unified schema + 22 类 canonical taxonomy)。
- 本组实验产物: `report_artifacts/result_summary.csv`、`analysis_notes.md`、各 `M*_summary.md`、`REPRODUCTION.md`。